

시위는 개선을 부르는가, 통제를 부르는가?

1912 년 Lawrence Textile Strike 신문기사 기반 인과 프레이밍 분석

Causal Inference and AI 기말 프로젝트 · Track B: 인문 데이터의 관계 분석

자료 출처: Library of Congress / Chronicling America

전자공학부 인공지능전공 2023028267 유가은

요약

본 프로젝트는 1912 년 Lawrence Textile Strike, 즉 “Bread and Roses” 파업을 둘러싼 신문 보도를 대상으로 한다. 연구 질문은 신문 지면이 Lawrence Strike 를 개선의 원인으로 구성했는가, 아니면 혼란과 통제의 원인으로 구성했는가이다. 이 프로젝트의 목표는 시위 프레이밍과 개선·통제 반응 사이의 인과효과를 분석하는 데 있다. 다만 본 자료는 1912 년 신문 OCR 8 개 호, 90 쪽으로 구성된 텍스트 corpus 이므로, 파업 전후 임금 변화, 비파업 지역 비교, 노동법 변화, 공장별 자료와 같은 외부 비교 자료 없이 실제 역사적 ATE 를 확정할 수는 없다. 따라서 본 보고서는 실제 역사 효과를 단정하지 않고, 신문 텍스트 안에서 식별 가능한 인과 프레이밍과 demo-coded adjustment 에서 나타나는 제한적 효과를 구분하여 분석한다.

분석은 과제의 Track B 방식으로 설계하였다. Lawrence Strike 라는 별도 corpus 에 맞추어 자료 수집, OCR 정제, 프레이밍 추출, Knowledge Graph, Causal DAG, demo backdoor adjustment 를 연결하였다. 분석 결과, 신문 프레이밍 안에서 관찰되는 인과효과는 맥락 의존적이며, demo 추정에서 보정된 두 경로(+0.101, +0.121)는 모두 양의 방향을 보였지만, 효과 크기가 크지 않아 어느 한쪽이 압도적이라고 보기는 어렵다. 자세한 해석은 결론에서 다룬다.



그림 1. 전체 분석 파이프라인: OCR 수집, 정제, 프레이밍 추출, KG/DAG 구축, demo adjustment 계산

1. Step 1 — Source text 획득과 corpus 범위 설정

이 단계에서는 작지만 근거를 추적할 수 있는 corpus 를 만드는 것을 우선했다. 본 프로젝트는 1912 년 1 월부터 3 월까지 Lawrence Strike 보도가 포함된 Chronicling America 신문 8 개 호, 총 90 쪽 OCR 을 분석 대상으로 삼았다. 분석 대상에는 *The Evening Standard*, *Daily Kennebec Journal*, *The Washington Times*가 포함된다.

분석 단위는 두 층위로 나누었다. 첫째, issue-level 은 한 신문 호 전체의 분위기와 어휘 환경을 파악하기 위해 사용하였다. 둘째, article-level 은 Lawrence Strike 관련 기사에서 실제 프레이밍과 인용 근거를 추출하기 위해 사용하였다. 이렇게 나눈 이유는 결과변수인 개선 반응(Y1)과 질서 통제 반응(Y2)은 파업 관련 기사에서만 코딩해야 하지만, 신문 전체의 분위기는 맥락 변수 Z 를 설정하는 데 필요하기 때문이다. 예를 들어

같은 신문 호에 실린 은행법 기사나 범죄 기사를 파업의 결과로 코딩하면 오류가 되지만, 그런 기사들이 지면 전체의 질서 중심 분위기를 보여주는 보조 근거가 될 수는 있다.

이는 과제에서 제시한 방식 중 Chronicling America 의 다른 제목과 날짜 범위를 선택하는 방향에 해당한다. 이 선택의 이유는 두 가지이다. 첫째, Lawrence Strike 는 시위, 노동조건, 폭동, 경찰, 조사, 임금 인상이라는 인과적 언어가 풍부하게 등장하는 역사적 사건이다. 둘째, 신문별·시기별 보도 차이가 있어 “개선 프레임”과 “통제 프레임”을 비교하기에 적합하다.

2. Step 2 — OCR 정제와 원문 보존

두 번째 단계에서는 원문 OCR 을 정제하되, 원문과 해석을 분리하였다. 1912 년 신문 OCR 에는 gate 가 gato, shut 이 Bhut, hands 가 nands 처럼 인식되는 오류가 있었다. 이런 오류를 그대로 두면 인용문 확인과 키워드 검색이 어렵다. 그래서 scripts/clean_ocr.py 를 사용해 줄바꿈, 하이픈, 공백, 혼한 OCR 오류를 규칙 기반으로 정리하고 cleaning log 를 남겼다.

본 프로젝트는 작은 corpus 의 감사 가능성을 우선했기 때문에 Step 2 의 Option C, 즉 라이브러리/규칙 기반 정제와 가벼운 수동 검토에 가까운 방식을 선택했다. 이 방식은 자동으로 매끄러운 문장을 만들지는 못하지만, 어떤 정제가 이루어졌는지 추적하기 쉽고, 의미가 바뀌는 교정을 줄일 수 있다.

원문 OCR 은 data/raw/ocr/에 그대로 보존하고, 정제된 텍스트는 data/cleaned/에 따로 저장하였다. 또한 추출에 사용한 인용은 원문 OCR 인용과 교정 인용을 함께 기록하였다. 이렇게 한 이유는 이후 “이 프레이밍이 실제 신문 문장에서 나온 것인가?”라는 질문에 답하기 위해서이다. 즉 정제는 분석 편의를 위한 과정이고, 근거의 최종 기준은 원문 OCR 과 source span 이다.

3. Step 3 — 정보 추출: causal framing 과 source span

세 번째 단계에서는 신문 문장을 구조화된 기록으로 바꾸었다. 단순히 protest, police, wage 같은 키워드 빈도를 세는 것이 아니라, 실제 기사 문장과 source span 을 기준으로 인과 프레이밍을 코딩하였다. 이 선택은 Step 3 의 Option C, 즉 작은 gold set 을 정의하고 검증하는 방식에 가깝다. LLM 대량 추출보다 속도는 느리지만, 작은 corpus 에서는 정확성과 근거 추적성이 더 중요하다고 판단했다.

추출 schema 는 수업의 인과추론 개념을 신문 프레이밍에 맞게 바꾼 것이다. X 는 시위 압력 프레이밍, Y1 은 발전 지향 개선 반응, Y2 는 질서 통제 반응으로 두었다. 또한 X 가 결과로 이어지는 중간 해석 경로를 설명하기 위해 M1 은 요구 정당화 프레이밍, M2 는 혼란·충돌 프레이밍으로 설정하였다. Z 는 X 와 Y 에 동시에 영향을 줄 수 있는 신문 맥락 혼란변수로 정의하였다.

구체적으로 X 는 파업, 군중, 공장 폐쇄, 집단 행동이 사회적 압력으로 보도되는 경우이다. M1 은 임금, 노동시간, 생계, 공정성 같은 정당화 프레이밍이고, Y1 은 조사·청문회·합의·임금 인상 등 개선 반응이다. M2 는 폭동, 위험, 충돌 같은 혼란 프레이밍이며, Y2 는 경찰·민병대·체포 등 질서 통제 반응이다. Z 는 order_focused, mixed, institutional 로 나눈 신문 맥락이며, 이후 robustness check 에서는 데이터가 더 직접적으로 지지하는 order_focused 대 reform_leaning 의 2 단계 구분도 함께 사용하였다.

총 26 개의 프레이밍 단위를 추출하였다. 이때 가장 중요하게 구분한 것은 asserted causation 과 analyst-added causal model 이다. 신문이 직접 “임금 삭감 때문에 소요가 발생했다”처럼 쓴 문장은 역사적 행위자 또는 신문이 주장한 인과로 기록하였다. 반면 $X \rightarrow M1 \rightarrow Y1$, $X \rightarrow M2 \rightarrow Y2$ 경로는 여러 기사에서 관찰된 프레이밍을 바탕으로 만든 분석용 DAG 이다. 이 구분을 둔 이유는 과제의 핵심 요구처럼, 텍스트 안에서 주장된 인과와 실제로 식별 가능한 인과효과를 혼동하지 않기 위해서이다.

4. Step 4 — Knowledge Graph 구축

네 번째 단계에서는 추출 결과를 Knowledge Graph 로 구조화하였다. 본 프로젝트는 Neo4j 대신 graph/nodes.csv 와 graph/edges.csv 를 사용하는 Option C 를 선택하였다.

Knowledge Graph 의 목적은 복잡한 시각화가 아니라 출처 추적성이다. 하나의 프레이밍 주장이 어떤 신문 호에서 나왔는지, 어떤 기사에 속하는지, 어떤 인용문에 의해 뒷받침되는지를 확인할 수 있어야 한다. 그래서 Issue, Article, Extraction, FramingClaim, AssertedCausalClaim, AnalystAssumption, SupportingQuote 노드를 만들고, 예시 스키마와의 연결을 위해 인용에 근거한 Person, Organization, Place, Event 엔티티 노드를 MENTIONS 관계로 추가하였으며, 기본 구조를 Issue → Article → Extraction → SupportingQuote 로 설계하였다.

이 구조를 사용한 이유는 두 가지이다. 첫째, “파업이 혼란으로 보도되었다”는 해석이 실제 원문 인용으로 돌아갈 수 있어야 한다. 둘째, 신문이 직접 주장한 인과와 추가한 DAG 가정을 서로 다른 노드 유형으로 분리해야 한다. 즉 Knowledge Graph 는 DAG 의 근거 저장소이자, asserted causation 과 analyst-added model 을 분리하는 장치로 사용되었다.




그림 2. Knowledge Graph: 신문 호, 기사, 추출, 인용 근거가 연결되는 방식

5. Step 5 — Causal DAG 와 식별 진단

다섯 번째 단계에서는 Knowledge Graph 에서 확인한 프레이밍 구조를 바탕으로 focused DAG 를 만들었다. 선택한 방식은 Step 5 의 Option B 이다. 즉 하나의 연구 질문에 맞추어 DAG 를 설계하고, 각 edge 를 corpus 근거와 변수 역할로 정당화하였다.

DAG 의 핵심은 두 개의 경쟁 경로이다. 첫 번째는 개선 지향 경로인 $X \rightarrow M1 \rightarrow Y1$ 이다. 이는 시위 압력 프레이밍이 임금, 노동시간, 생계, 공정성 같은 요구 정당화 프레이밍을 거쳐 조사, 청문회, 임금 인상, 합의 같은

개선 반응으로 이어지는 구조이다. 두 번째는 질서 통제 경로인 $X \rightarrow M2 \rightarrow Y2$ 이다. 이는 시위 압력 프레이밍이 폭동, 위험, 충돌 같은 혼란 프레이밍을 거쳐 경찰, 민병대, 체포, 진압 같은 통제 반응으로 이어지는 구조이다.

신문 맥락 Z는 confounder로 설정하였다. 그 이유는 신문 자체의 보도 맥락이 시위 프레이밍 X에도 영향을 줄 수 있고, 동시에 개선 반응 Y1 또는 질서 통제 반응 Y2를 얼마나 강조하는지에도 영향을 줄 수 있기 때문이다. 예를 들어 order_focused 신문은 파업을 강하게 다루면서도 개선보다 폭동, 경찰, 민병대 같은 통제 프레임에 강조할 수 있다. 이런 경우 단순한 $P(Y|X)$ 는 신문 맥락의 영향을 함께 포함하므로 Z를 보정할 필요가 있다.

반대로 M1과 M2는 보정하지 않았다. 이들은 X와 Y 사이의 causal path 위에 있는 mediator이기 때문이다. 만약 M1 또는 M2를 통제하면, 시위 프레이밍이 개선 또는 통제 반응으로 이어지는 경로 자체를 막게 된다. 따라서 본 프로젝트의 보정 대상은 mediator가 아니라 common cause 역할을 하는 Z이다. 또한 같은 기사 안에서 X, M1, M2가 함께 등장하는 경우는 엄밀한 시간적 인과라기보다 서사적 공동 구성으로 해석하였다.




그림 3. Causal DAG: 개선 지향 경로와 질서 통제 경로, 그리고 신문 맥락 Z의 역할

식별 진단 결과, 실제 corpus 만으로는 X의 역사적 causal effect를 식별할 수 없다. 대부분의 분석 단위가 Lawrence Strike 관련 기사이므로 $X=1$ 사례가 중심이고, 적절한 $X=0$ 비교군이 부족하다. 따라서 본 프로젝트는 실제 파업 효과를 확정 추정하지는 못하지만, DAG를 통해 어떤 혼란변수를 보정해야 하는지 진단하고, corpus 관찰에 근거한 demo-coded data로 backdoor adjustment를 수행하여 신문 프레이밍 효과의 방향과 크기가 어떻게 달라지는지 시연한다.

6. Step 6 — Inference와 비판적 해석

여섯 번째 단계에서는 DAG를 바탕으로 inference를 수행하였다. 실제 사회경제 데이터가 없기 때문에 Step 6의 Option B를 완전한 역사적 효과 추정으로 적용하지는 못한다. 대신 quantitative effect estimation의 형식을 제한적으로 사용하여, demo-coded data 안에서 신문 맥락 Z를 보정했을 때 시위 프레이밍의 효과

추정치가 어떻게 달라지는지 확인하였다. 따라서 여기서 말하는 효과는 Lawrence Strike 의 실제 사회경제적 효과가 아니라, 신문 프레이밍 자료를 바탕으로 구성된 demo framing effect 이다.

Backdoor adjustment 공식은 다음과 같다. $P(Y=1 | do(X=x)) = \sum_z P(Y=1 | X=x, Z=z) \cdot P(Z=z)$.

Demo-coded data 는 160 개 단위로 구성되었고, 각 맥락 Z 안에서 X와 Y1/Y2 의 관계가 어떻게 달라질 수 있는지를 보여주도록 설계하였다. 이 설계는 실제 corpus 의 관찰을 참고하되, 실제 역사 효과를 직접 추정하기 위한 데이터가 아니라 조정 절차와 효과 크기 해석을 설명하기 위한 시연 자료이다. order_focused 맥락에서는 통제 프레임이 강했고, reform-leaning 쪽 보도에서는 개선 프레임이 더 자주 나타났다는 관찰을 반영하였다.

핵심 결과는 두 가지로 정리된다. Y1 개선 반응은 naive comparison 에서 +0.022 였고, 신문 맥락 Z 를 보정한 뒤에는 +0.101로 나타났다. Y2 질서 통제 반응은 naive comparison 에서 +0.195 였고, Z 보정 뒤에도 +0.121의 양의 관계를 유지하였다.




그림 4. Demo effect estimation: naive comparison 과 Z 보정 후 결과의 차이

결과를 해석하면, demo 계산은 통제 프레임이 강하다는 단순 인상을 그대로 확정하기보다, 신문 맥락 Z 를 보정하면 가려져 있던 개선 신호가 드러나고(+0.022→+0.101) 크게 보이던 통제 신호는 일부 줄어든다(+0.195→+0.121)는 점을 보여준다. 즉 order_focused 신문 맥락이 개선 경로를 가리고 통제 경로를 부각시킬 수 있다.

민감도 분석도 수행하였다. P(Z)를 demo-balanced 에서 observed-issue share 로 바꾸어도 Y1 은 +0.101에서 +0.124, Y2 는 +0.121 에서 +0.116 으로 유지되었다. 또한 데이터가 실제로 지지하는 2 단계 Z(order_focused vs reform_leaning)로 collapse 하여 다시 계산해도 Y1 +0.080, Y2 +0.138 로 부호가 유지되었다. 따라서 결론은 특정한 Z 가중치나 범주 수 하나에만 의존하지 않는다.

위 수치는 모두 합성 demo 데이터에서 나온 방법 시연이므로, 합성에만 의존하지 않도록 실제 26 개 추출 자체의 rung-1 association 도 별도로 계산하였다. 실제 추출을 신문 맥락별로 집계하면, order_focused 맥락(Evening Standard 1월 호)에서는 개선 반응(Y1) 단위가 0 개, 질서 통제(Y2) 단위가 2 개로 통제 쪽으로 기울었다. 반면 mixed 맥락에서는 Y1 7 개 대 Y2 3 개, institutional 맥락에서는 Y1 2 개 대 Y2

0 개로, 후반 보도일수록 개선 프레임이 더 자주 나타났다. 따라서 실제 corpus 의 서술적 연관은 “초기 통제, 후기 개선 재구성”이라는 2 단계 흐름에 가깝다. 이 대비는 단순 연관, demo adjustment, 실제 역사 효과를 분리해 해석해야 함을 보여준다.

마지막으로 결과는 세 층위를 구분해서 해석해야 한다. Correlation 수준에서는 초기 order_focused 보도가 통제 쪽으로, 후반 mixed/institutional 보도가 개선 쪽으로 기운다. Asserted causation 수준에서는 일부 신문이 임금 삭감, 소요, 제도적 대응 사이의 인과를 직접 서술했다. Identified causal effect 수준에서는 실제 역사적 효과를 식별할 수 없으며, demo-coded data 안의 adjusted framing effect 만 제한적으로 해석할 수 있다.

결론

이 프로젝트에서 Knowledge Graph 로 근거를 구조화하고 Causal DAG 를 설계한 이유는 단순한 신문 프레임링 요약을 넘어서, 신문 프레임링 안에서 시위 압력 프레임링이 개선 반응 또는 질서 통제 반응과 어떤 인과적 관계를 갖는지 분석하기 위해서다. 다만 실제 역사 효과를 식별할 비교군이 부족하므로, 본 연구는 식별 가능한 효과와 식별 불가능한 효과를 분리한다. Demo data 에서 개선 경로($X \rightarrow Y1$)는 보정 전 +0.022 에서 Z 보정 후 +0.101 로 커졌고, 통제 경로($X \rightarrow Y2$)는 +0.195 에서 +0.121 로 줄었다. 이는 신문 맥락을 고려하면 개선 신호가 가려져 있었고 통제 신호는 일부 과대평가되어 있었을 수 있음을 보여준다. 그러나 보정된 두 값은 모두 크지 않으며, 어느 한쪽이 다른 쪽을 압도한다고 말하기는 어렵다.

따라서 “인과효과가 미미했다”고 말할 수 있는 범위는 실제 역사 전체가 아니라 demo-coded framing analysis 안으로 한정된다. 이 범위 안에서는 개선 경로와 통제 경로 모두 양의 방향을 보였지만, 효과 크기는 작고 결정적이지 않았다. 실제 Lawrence Strike 가 사회 개혁을 얼마나 일으켰는지는 이 자료만으로 식별되지 않는다. 본 프로젝트의 의의는 신문 아카이브의 인과 주장을 DAG 로 정식화하고, 혼란변수 Z 를 보정할 때 단순 상관의 해석과 demo 효과 추정이 어떻게 달라지는지를 보여준 데 있다.

한계

본 분석에는 네 가지 한계가 있다. 첫째, demo adjustment 의 수치(+0.101, +0.121)는 실제 역사 효과가 아니라 corpus 관찰을 바탕으로 설계한 framing effect 시연이다. 이를 보완하기 위해 실제 추출 기반의 보정되지 않은 rung-1 association 을 함께 제시하였다. 둘째, Z 는 정밀한 측정변수가 아니라 order_focused 대 reform-leaning 구분을 중심으로 한 휴리스틱이다. 셋째, order_focused 층위는 The Evening Standard 1912 년 1 월 15 일 단일 호이고, 후반의 개선 프레임은 주로 Daily Kennebec Journal 과 Washington Times 에서 나오므로 신문 정체성과 시점 효과를 완전히 분리할 수 없다. 넷째, iss003 은 추출 0 건이지만 전체 corpus 의 일부이므로 Knowledge Graph 에는 context-only issue 노드로 유지하였다.